CPES2 : UE « Pratique de la recherche »

Domaine « informatique »

Antoine GAUQUIER

26 septembre 2023

À propos de moi

Je suis doctorant au sein de l'équipe Valda du Département Informatique de l'*École normale supérieure*. Avant cela, j'ai suivi le cursus d'ingénieur généraliste de l'*IMT Nord Europe* (anciennement nommée *École des Mines de Douai*) que j'ai terminé par une année de spécialisation en intelligence artificielle et gestion de données à *Télécom Paris*.

Mes thématiques de recherche s'orientent autour de l'acquisition (massive) de données, l'extraction d'informations et de connaissances à partir de celles–ci, et leur gestion au sein de bases de données et de connaissances devant être intérrogeables par des *non–experts*. Mon sujet de thèse s'intitule : « *Construction intelligente d'un entrepôt de données multimodales et hétérogènes, avec traçabilité des données* », et s'inscrit dans ces thématiques. Je travaille ainsi sur un large panel de techniques d'intelligence artificielle dans ces thématiques, comprenant (entre autres) : l'apprentissage par renforcement pour les techniques de *crawling*, l'apprentissage profond et multimodal pour l'extraction d'informations, incluant les méthodes de traitement de la langue naturelle (*TAL*, ou *NLP* en anglais), de vision par ordinateur ou encore d'apprentissage séquentiel. Je travaille également sur les aspects gestion de données, et en particulier de *Big Data*, incluant la représentation des données dans leur hétérogénéité (triplets RDF, formats XML, JSON, ...) et leur intégration dans des bases de données ou de connaissances, incluant également les graphes.

À ce jour, j'ai été l'auteur ou le co–auteur de plusieurs publications scientifiques dans des conférences internationales. Parmi elles, deux papiers longs de recherche (un premier en tant qu'auteur principal [1], et un autre en tant que co–auteur [2]), une démonstration de système en tant que co–auteur [3], et un autre papier de recherche long *pré–publié* [4], qui sera soumis à une conférence en début d'année 2024.

Articles proposés aux étudiants

Je propose aux étudiants qui souhaitent s'investir dans le domaine informatique de cette UE, trois articles de recherche plus ou moins récents traitant de thématiques différentes :

— *Extracting Structured Data from Web Pages* [5]. Cet article paru en 2003 dans la conférence *SIGMOD '03* porte sur l'extraction de données structurées présentes sur les sites web. Les auteurs partent du constat que beaucoup de pages utilisent des *modèles* ou des *structures* (respectivement, *templates* et *frameworks* en anglais) afin d'afficher des données

qui proviennent de *bases de données relationnelles* structurées. Ils proposent alors une méthode d'extraction du contenu de ces pages afin de reconstruire les bases de données utilisées, et ce sans utiliser d'apprentissage machine, ne nécessitant donc pas de données annotées humainement. Cet article porte donc sur l'extraction et la gestion de données (sans toutefois faire appel à de l'intelligence artificielle), à portée applicative sur le Web.

— *Tab this Folder of Documents : Page Stream Segmentation of Business Documents* [6]. Cet article paru en 2022 dans la conférence *DocEng '22* porte sur la segmentation automatique d'un flux de pages constituant plusieurs documents. Les auteurs partent du constat que beaucoup d'entreprises scannent un grand nombre de documents tous contenus dans un dossier, résultant en un ensemble de pages scannées. Toutefois, ces documents ne forment plus qu'un seul bloc de pages et il devient impossible d'ensuite répartir ces documents selon une organisation différente, ou même de tout simplement directement accéder à un document en particulier. Les auteurs proposent donc une méthode de découpage automatique de ce flux de page, en faisant appel à deux modèles de la littérature regroupant des méthodes de vision par ordinateur et de traitement de la langue naturelle, toutes deux basées sur l'apprentissage profond. Cet article aborde le thème de l'extraction d'informations sur la base de méthodes d'intelligence artificielle récentes, avec une application sur la digitalisation des documents papiers et leur indexation / archivage.

— *Finding Related Pages Using Green Measures : An Illustration with Wikipedia* [7]. Cet article paru en 2007 dans la conférence *AAAI–07* porte sur la détermination de pages sémantiquement similaires à une autre page donnée. Les auteurs proposent une méthode purement mathématique (indépendante de toute application) permettant, à partir d'un graphe, de déterminer les noeuds du graphe qui sont les plus similaires à un noeud donné. Ils présentent une application au cas de l'archive en ligne *Wikipedia*, utilisant des données annotées manuellement afin de montrer la pertinence de leur approche. **Attention :** Cet article est mathématiquement plus formel que les deux précédents, même s'il reste abordable pour des étudiants curieux, qui devront faire quelques recherches sur les notions présentées dans l'article. Il aborde les sujets de l'extraction d'information, de la recommandation de contenu et de la théorie des graphes.

Références

[1] Antoine Gauquier and Pierre Senellart. Automatically Inferring the Document Class of a Scientific Article. In *23rd ACM Symposium on Document Engineering (DocEng 2023)*, Limerick, Ireland, August 2023. Nominated for ACM best paper award.

[2] Nelly Barret, Antoine Gauquier, Jia-Jean Law, and Ioana Manolescu. Exploring heterogeneous data graphs through their entity paths. In *27th European Conference on Advances in Databases and Information Systems (ADBIS 2023)*, Barcelona, Spain, September 2023.

[3] Nelly Barret, Antoine Gauquier, Jia-Jean Law, and Ioana Manolescu. PathWays: entity-focused exploration of heterogeneous data graphs. In *20th European Semantic Web Conference (ESWC 2023)*, Hersonissos (Crete), Greece, May 2023. Demonstration paper.

[4] Shrey Mishra, Antoine Gauquier, and Pierre Senellart. Multimodal Machine Learning for Extraction of Theorems and Proofs in the Scientific Literature. arXiv 2307.09047, May 2023.

[5] Arvind Arasu and Hector Garcia-Molina. Extracting Structured Data from Web Pages. In *Proceedings of the 2003 ACM SIGMOD International Conference on Management of Data*, SIGMOD '03, page 337–348, New York, NY, USA, 2003. Association for Computing Machinery.

[6] Thisanaporn Mungmeeprued, Yuxin Ma, Nisarg Mehta, and Aldo Lipani. Tab This Folder of Documents: Page Stream Segmentation of Business Documents. In *Proceedings of the 22nd ACM Symposium on Document Engineering*, DocEng '22, New York, NY, USA, 2022. Association for Computing Machinery. ACM best paper award.

[7] Yann Ollivier and Pierre Senellart. Finding Related Pages Using Green Measures: An Illustration with Wikipedia. In *Proc. AAAI*, pages 1427–1433, Vancouver, Canada, July 2007.